

# Dynamische Netzwerkanalysen

Eine Einführung

Björn Siepe

AE Psychologische Methodenlehre, Philipps-Universität Marburg

1/3/23

## Ziele

1. Hintergrund von Netzwerkanalysen erarbeiten
2. Den Sinn und die Struktur von Zeitreihendaten verstehen
3. Dynamische Netzwerke interpretieren können
4. Zentrale Annahmen und Einschränkungen erkennen
5. Junge Entwicklungen kennenlernen

Zusatz: Literaturliste am Ende

# Was wir auslassen

1. Querschnittliche Netzwerke im Detail
2. Planung von Längsschnittstudien
3. Eigene Schätzung von Netzwerken in R (-> Followup?)
4. N>1 dynamische Netzwerke im Detail
5. Details klinischer Theorie (Process-Based Therapy, Case Formulations etc.)

# Netzwerkperspektive

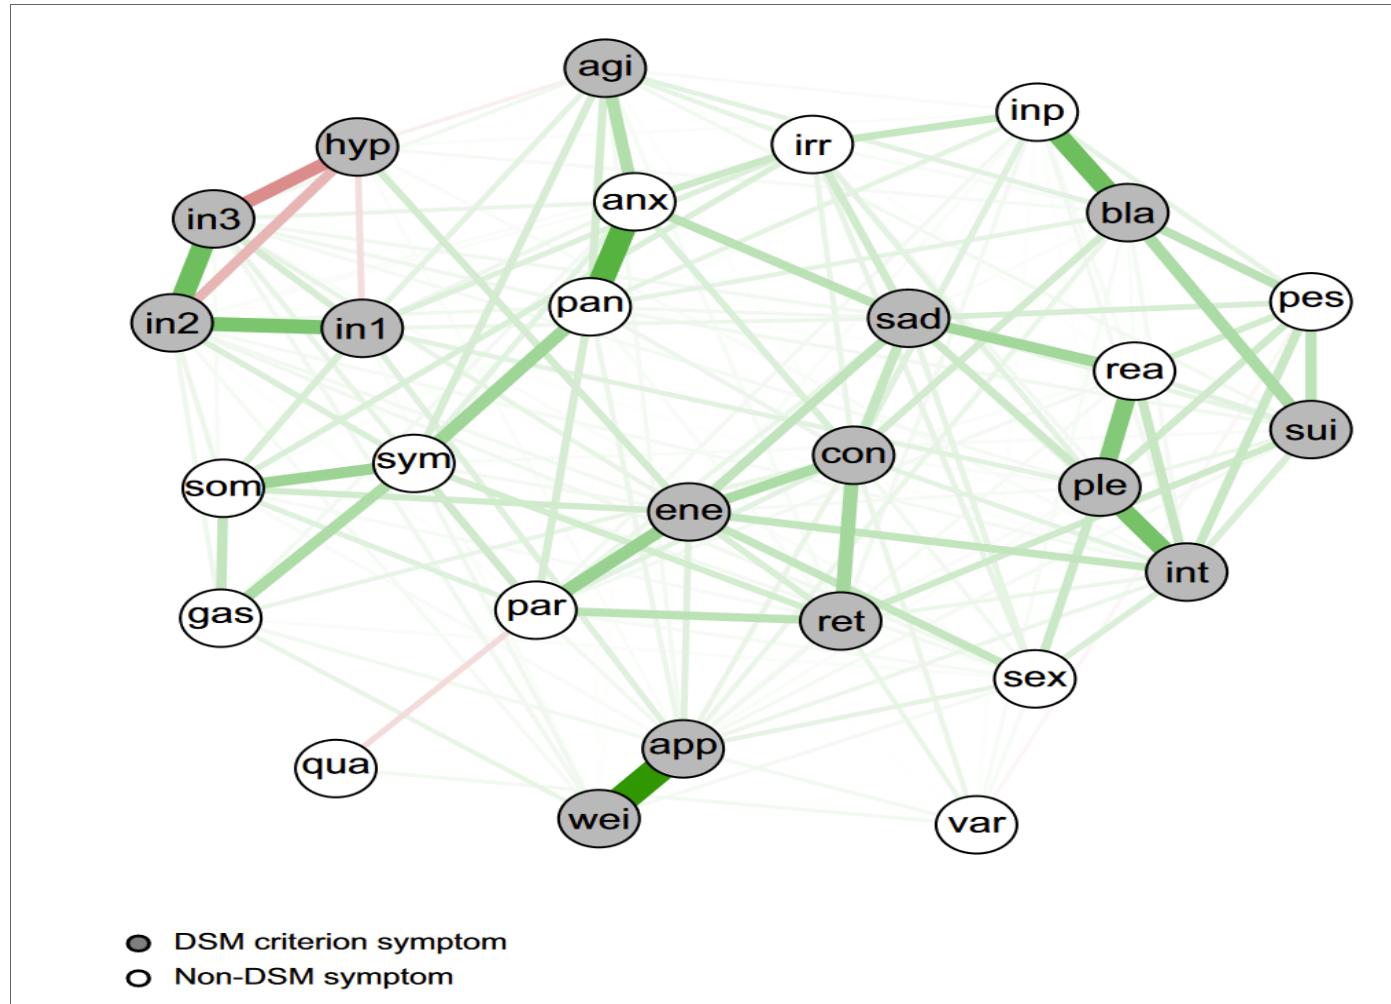


Foto von Garrett Sears ([unsplash](#))

# Netzwerke

- Netzwerke bestehen aus **Knoten** (nodes) und **Kanten** (edges)
- Knoten:
  - Personen, Städte, Maschinenteile, Symptome
- Kanten:
  - gewichtet/ungewichtet
  - direktonal/undirektonal
- In der Psychologie: erste Arbeiten ~2010

# Beispielnetzwerk

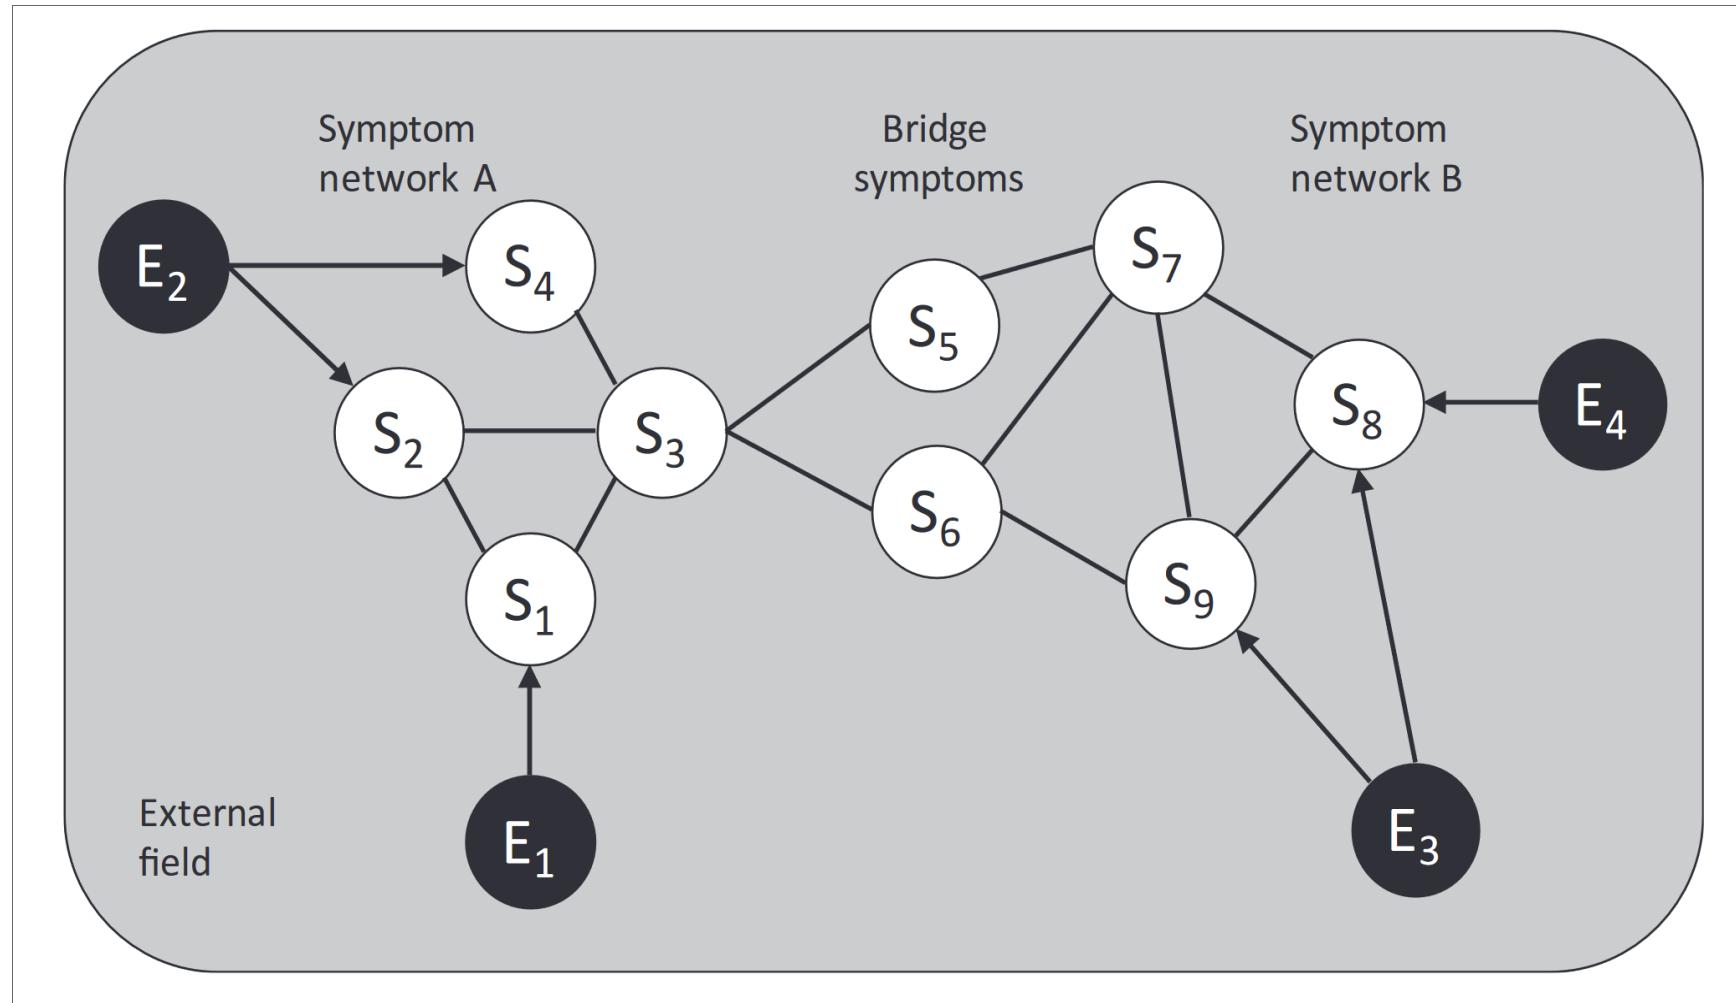


Fried et al. (2016)

# Netzwerke vs. traditionelle Vorstellungen

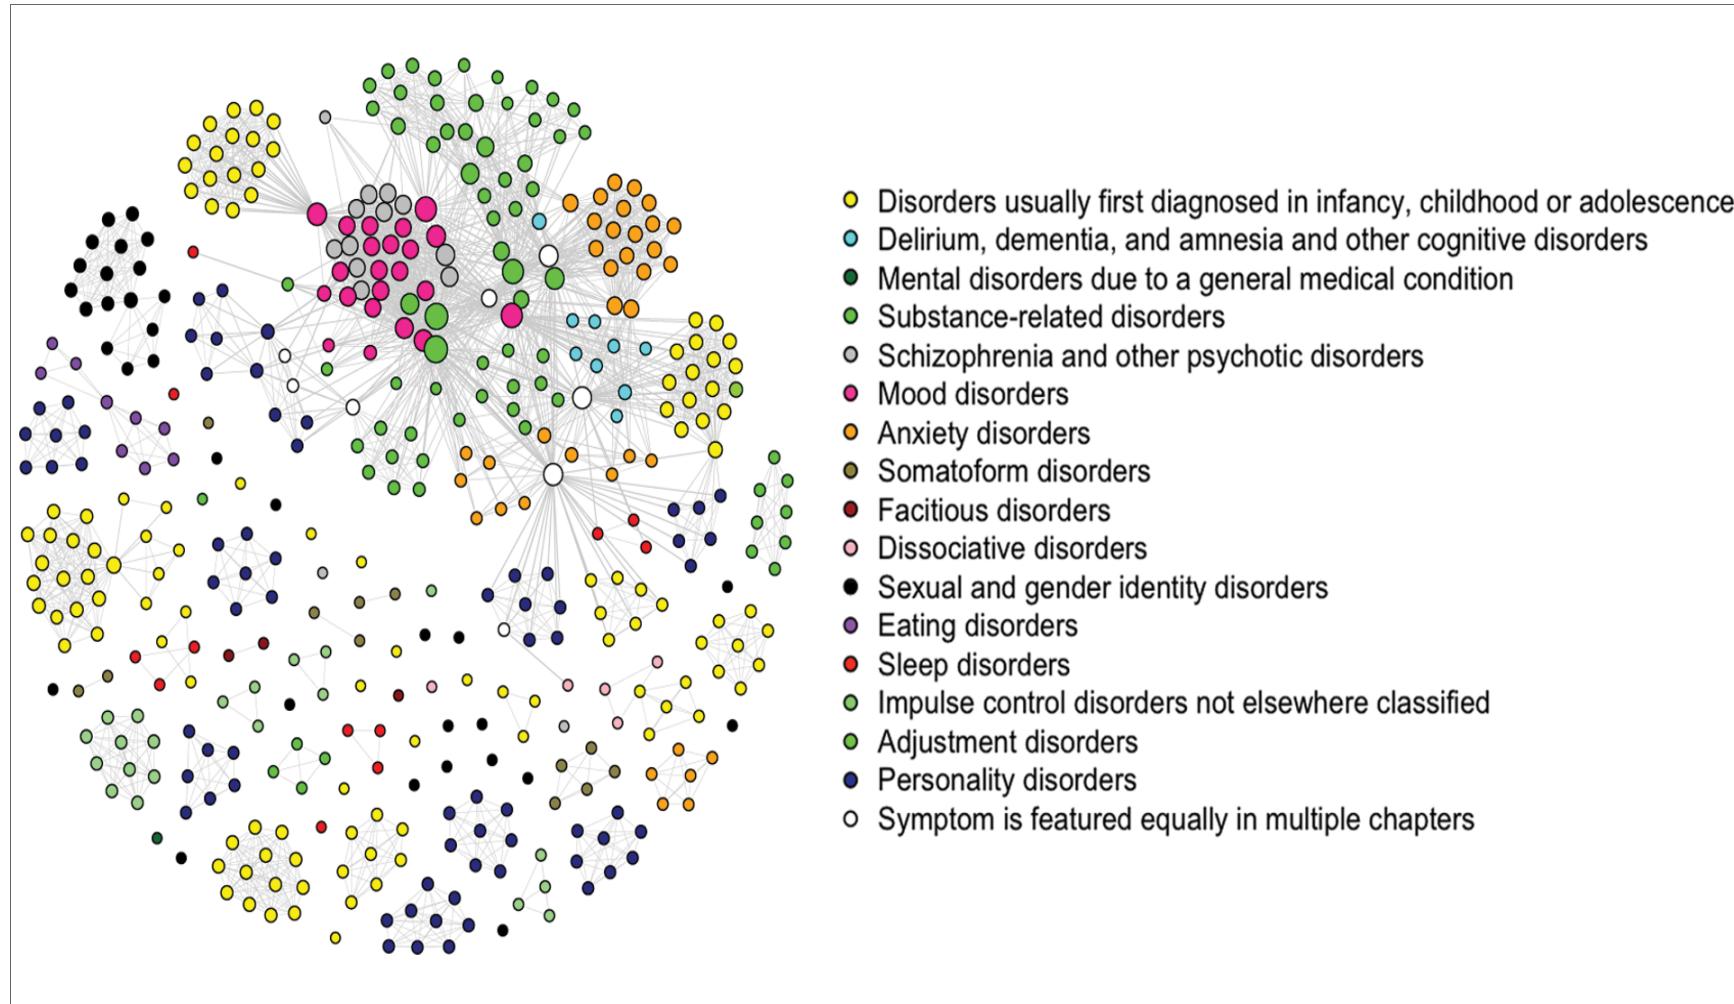
- Netzwerkmodell vs. Netzwerktheorie
- Netzwerktheorie:
  - kausale Interaktion von Symptomen anstatt Syndrome
  - verschiedene Zustände des Systems
  - stark verbundenes Netzwerk verstärken sich gegenseitig

# Komorbidität



Borsboom (2017)

# Small World



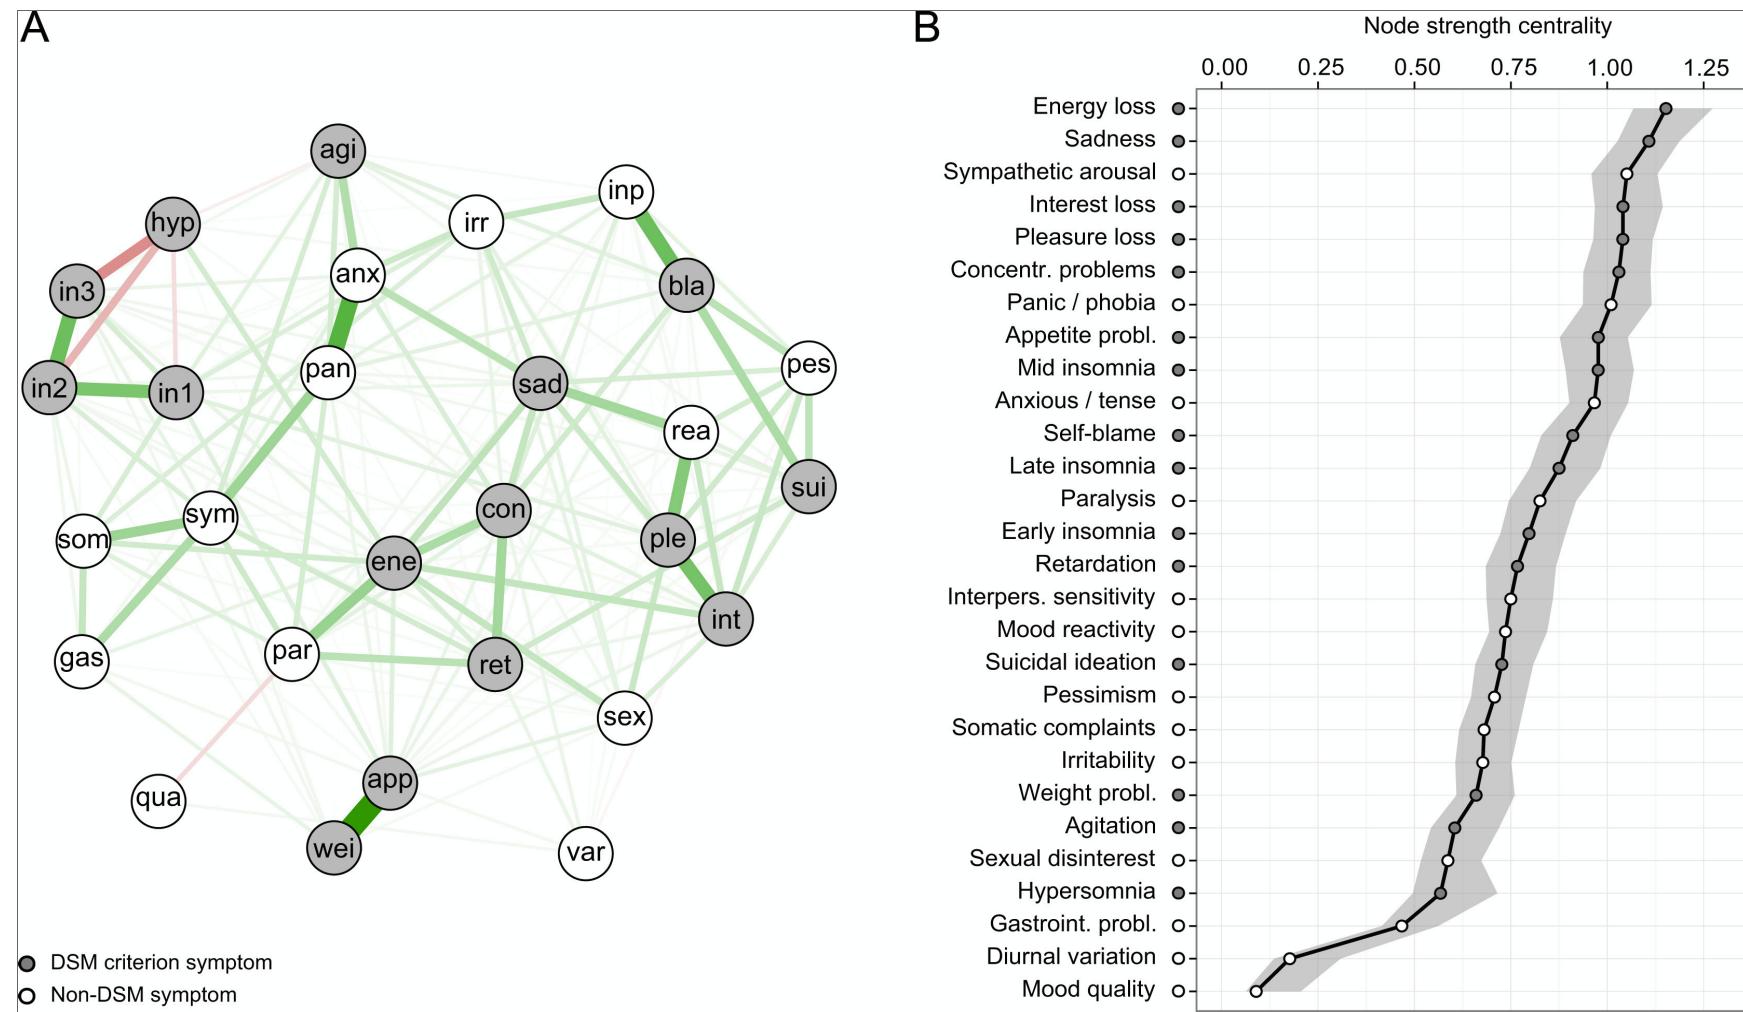
Borsboom et al. (2011)

# Zentralität

- Wichtigkeit eines Knotens
- Degree
  - Anzahl der Verbindungen
- Strength
  - Stärke der Verbindungen
- Betweenness
  - Anzahl der Pfade
- Beispiel: Flughafen
- Idee: Ansatz für Interventionen?
- Interpretation teils fraglich

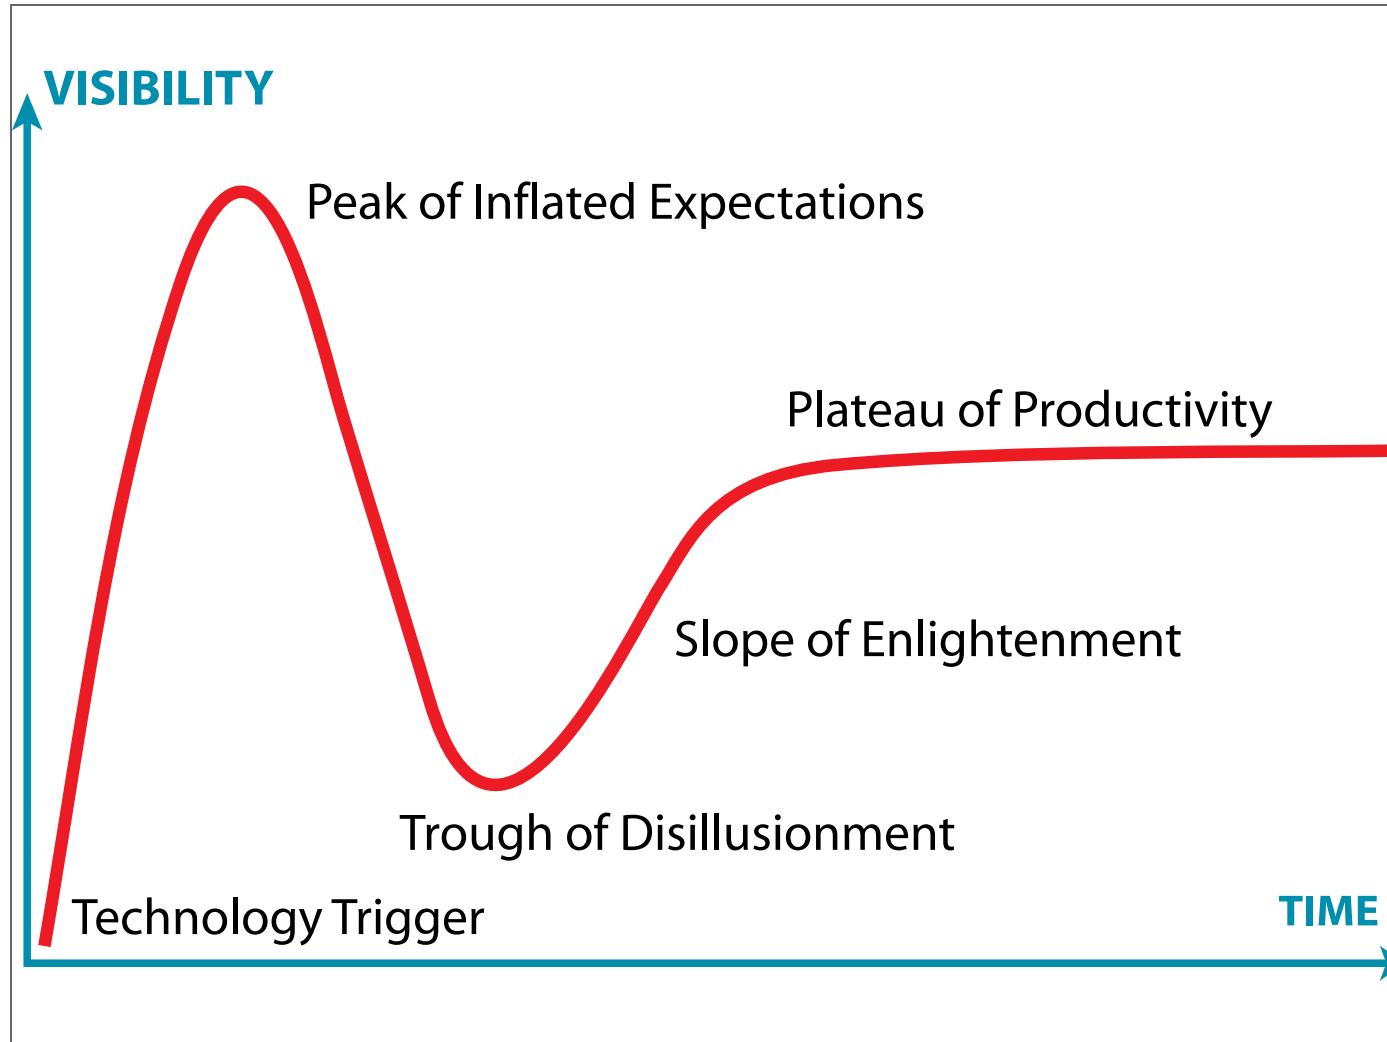
Bringmann et al. (2019), Dablander et al. (2019)

# Zentralität



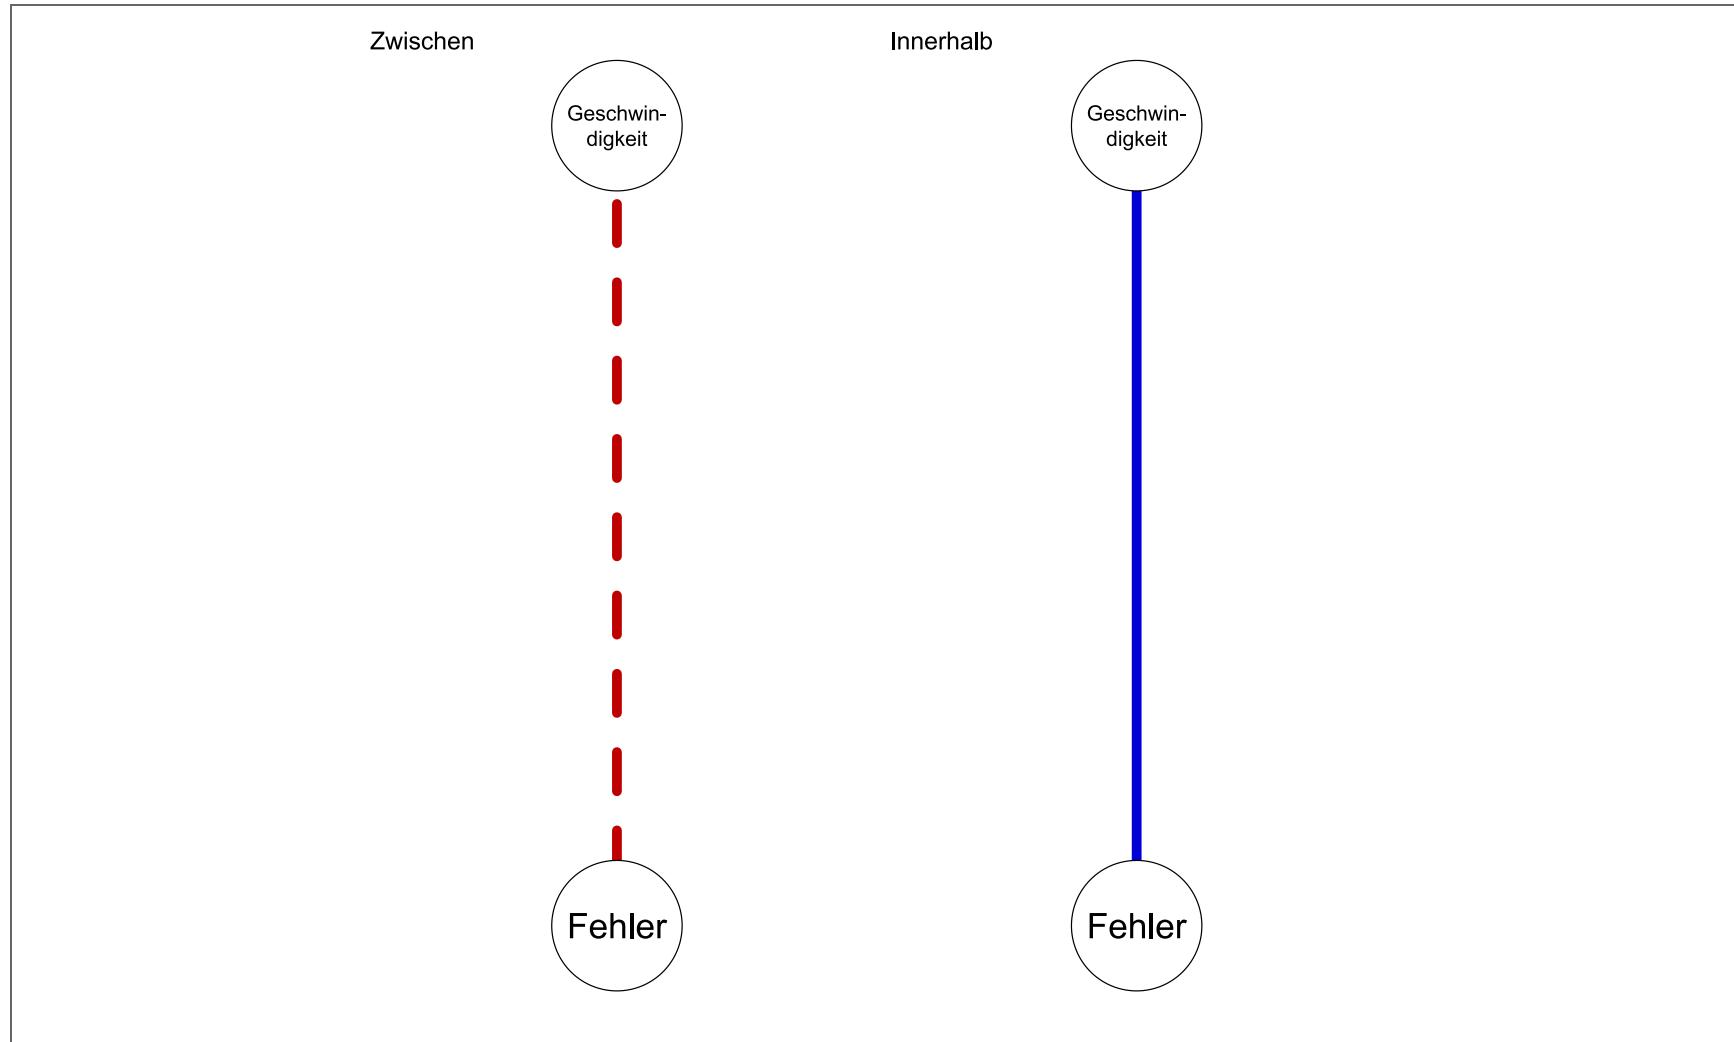
Fried et al. (2016)

# Hype Cycle



[Jeremykemp, Wikimedia](#)

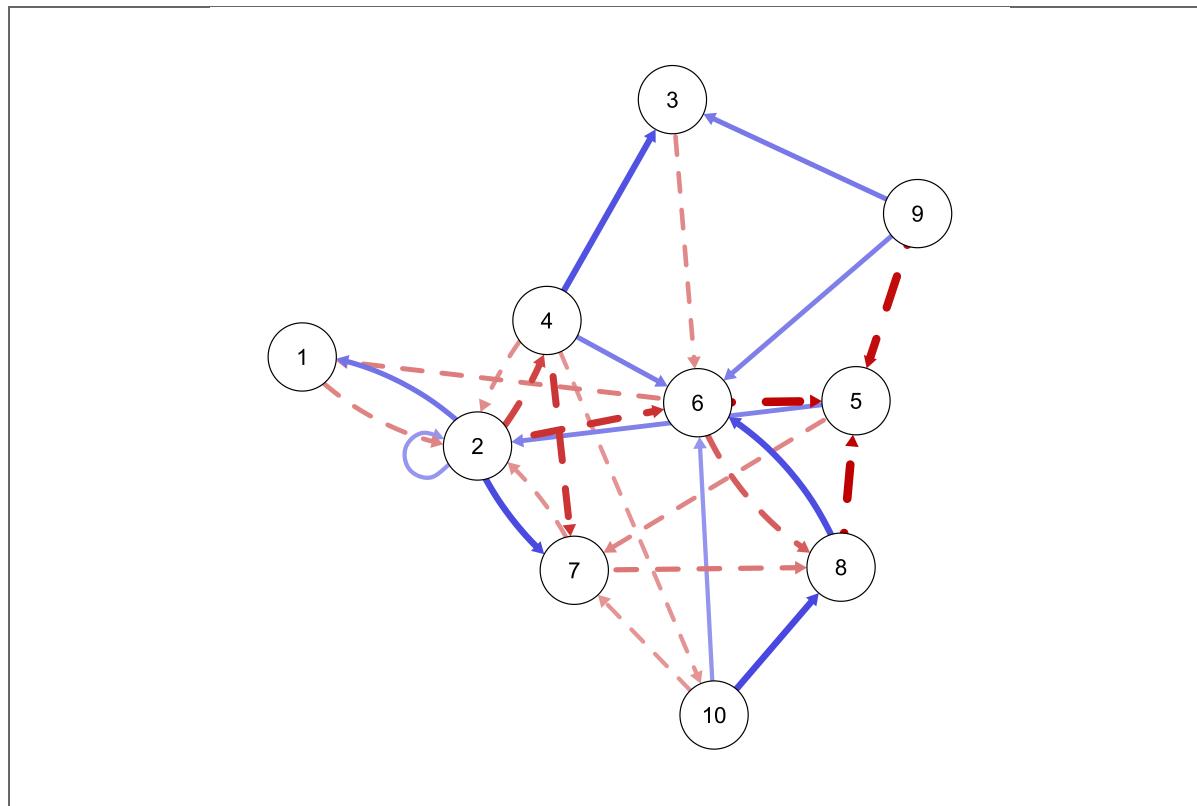
# Warum Längsschnitt?



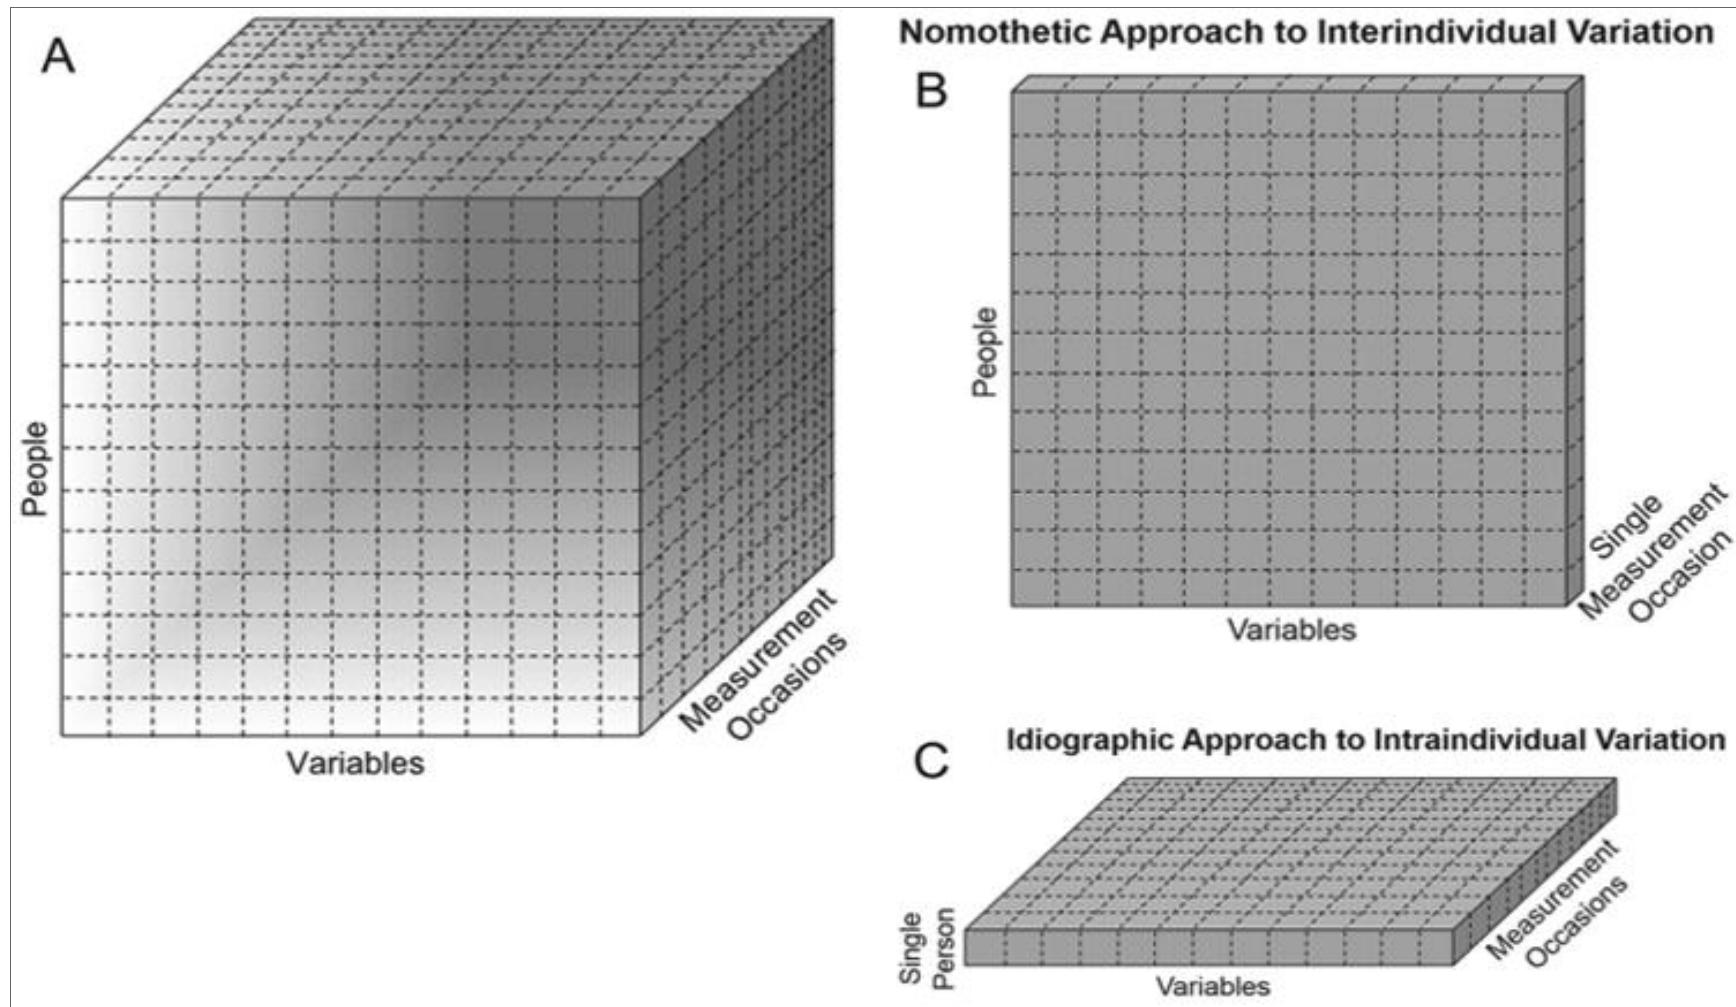
Angelehnt an Hamaker (2005)

# Dynamische Netzwerke

- dynamische Zusammenhänge innerhalb von Personen
- über Zeitpunkte hinweg
- Idiographie vs. Multilevel

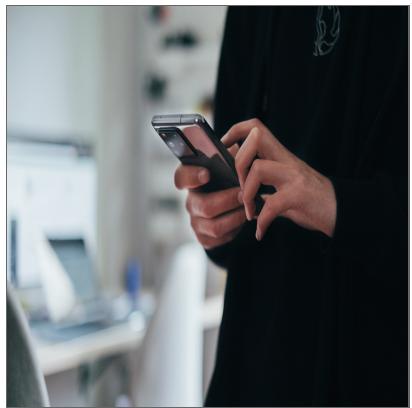


# Zeitreihendaten



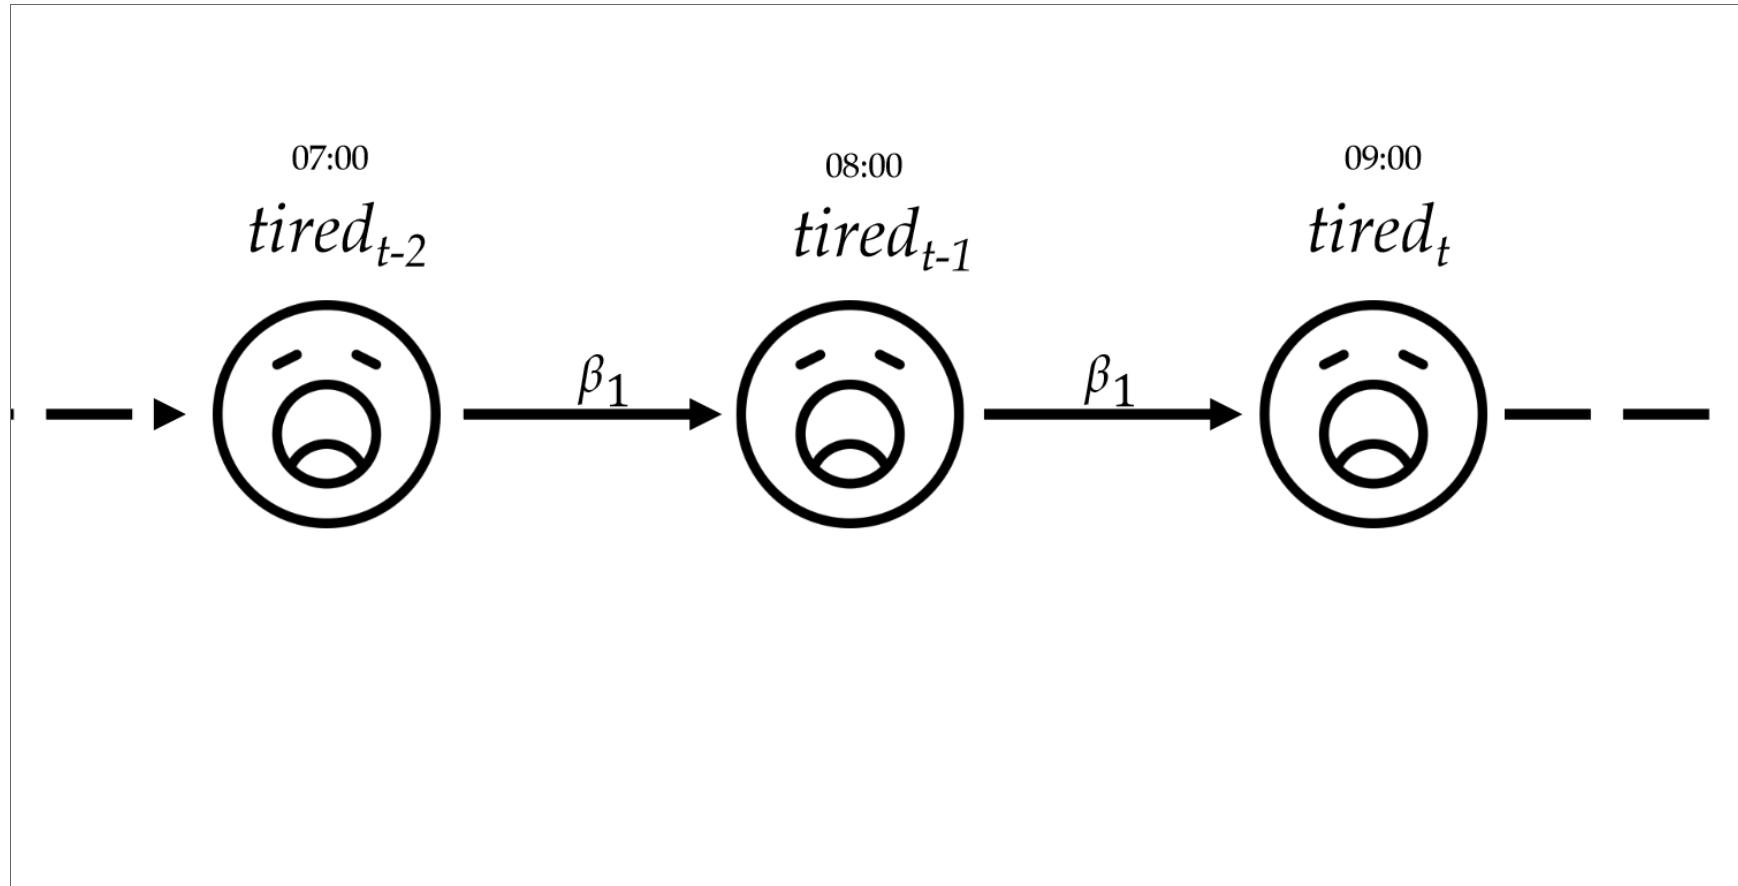
Beltz et al. (2016)

# Experience Sampling



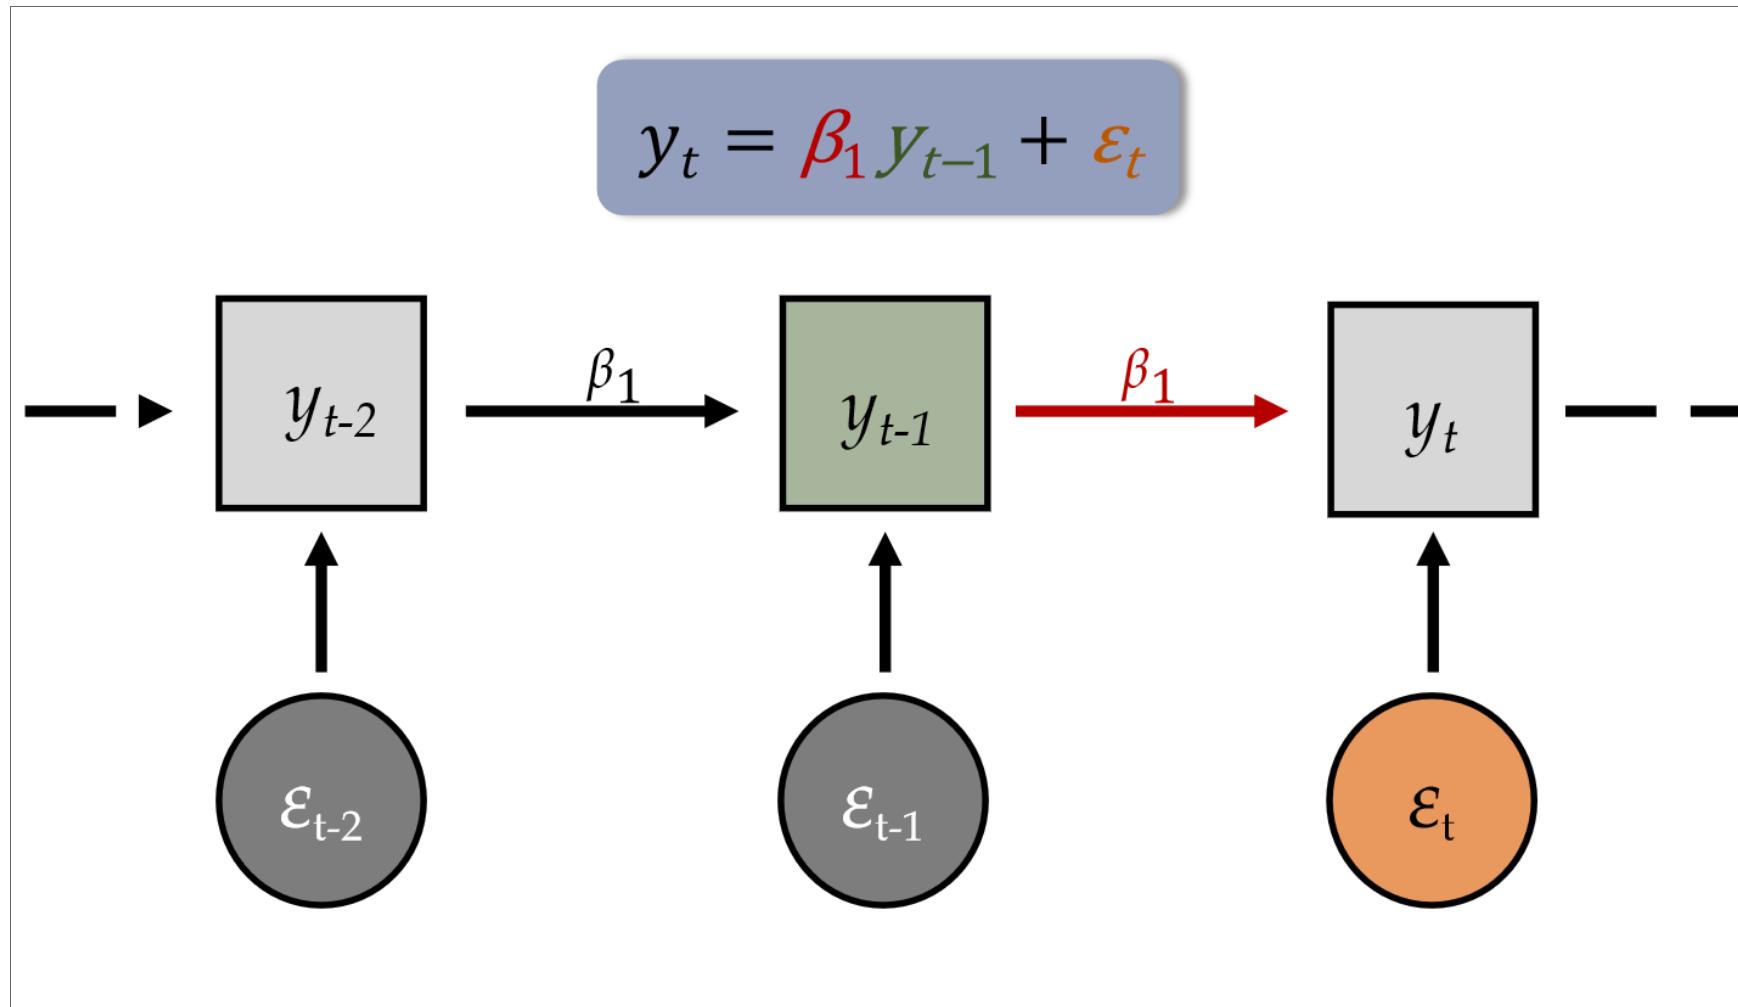
Sabina Ciesielska (Unsplash), Jonas Leupe (Unsplash)

# Autoregressiv

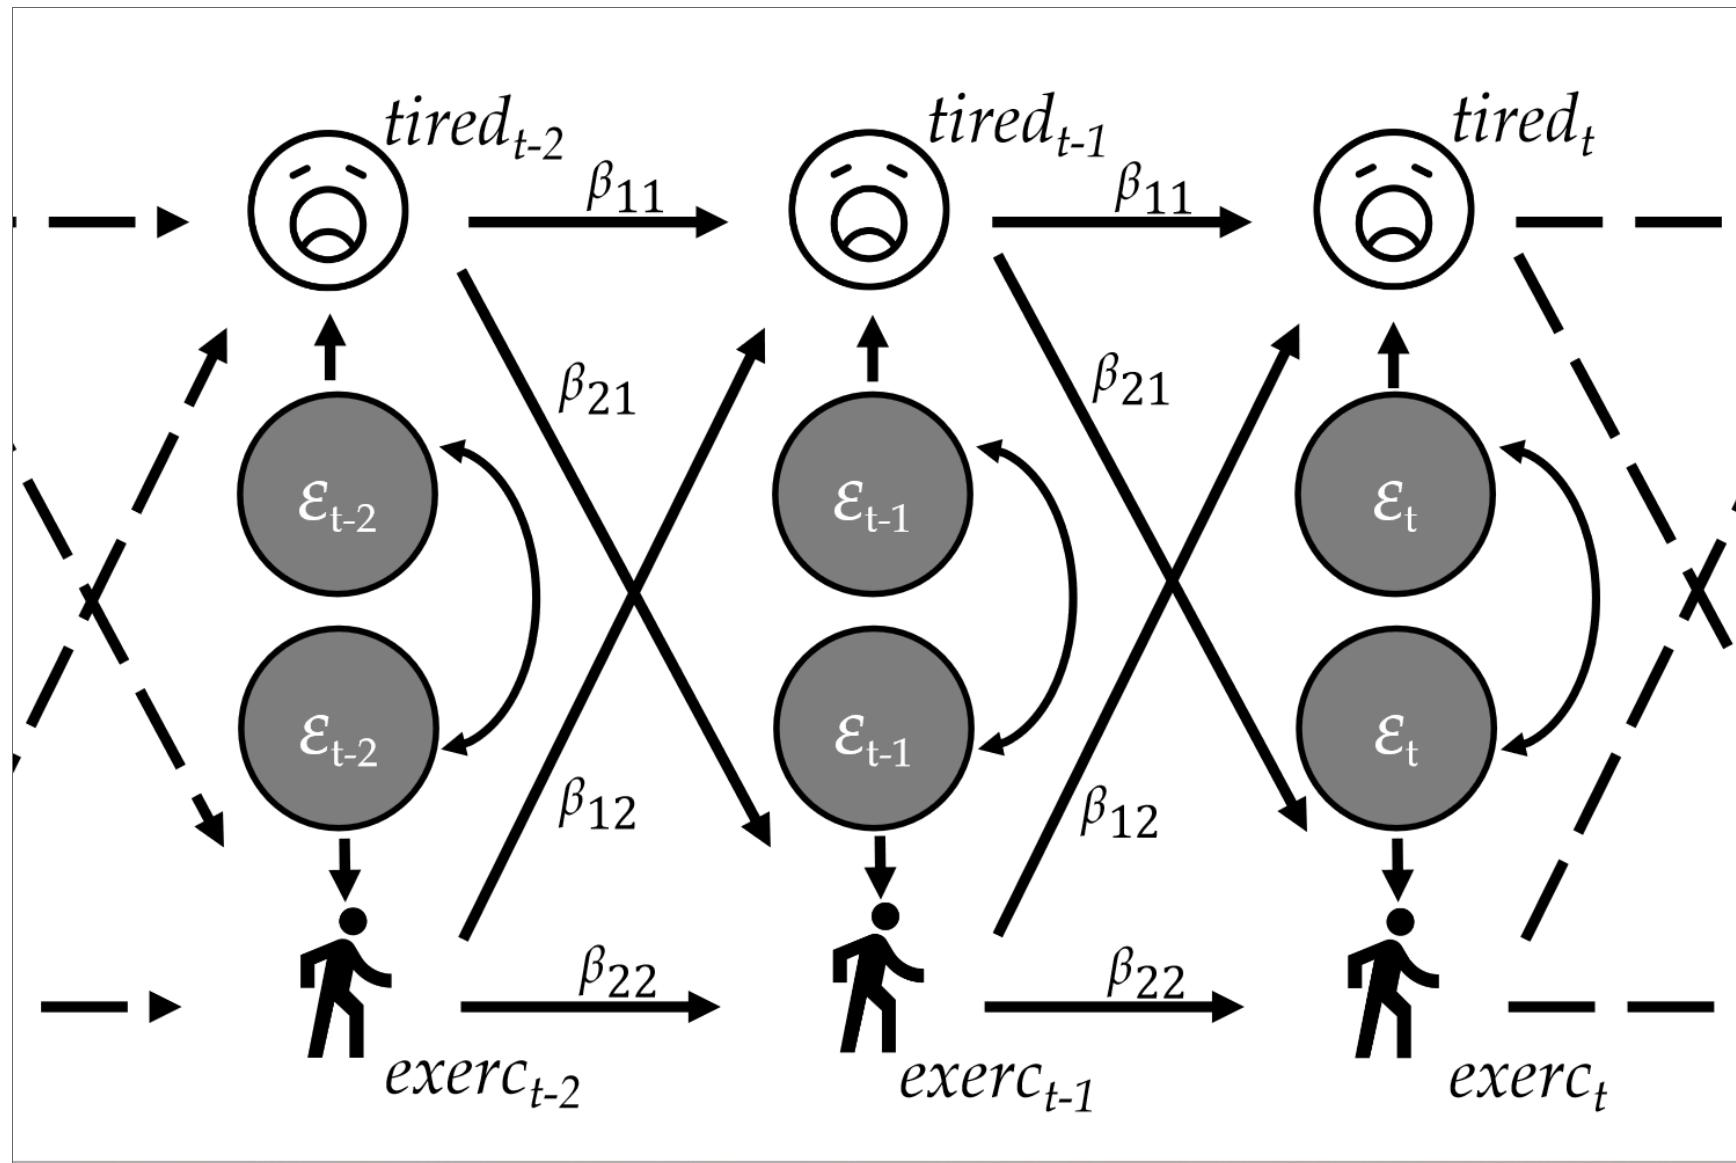


Nächste Folien von Julian Burger ([Link](#))

# Autoregressiv



## Cross-Lagged



# Schätzung idiographischer Netzwerke

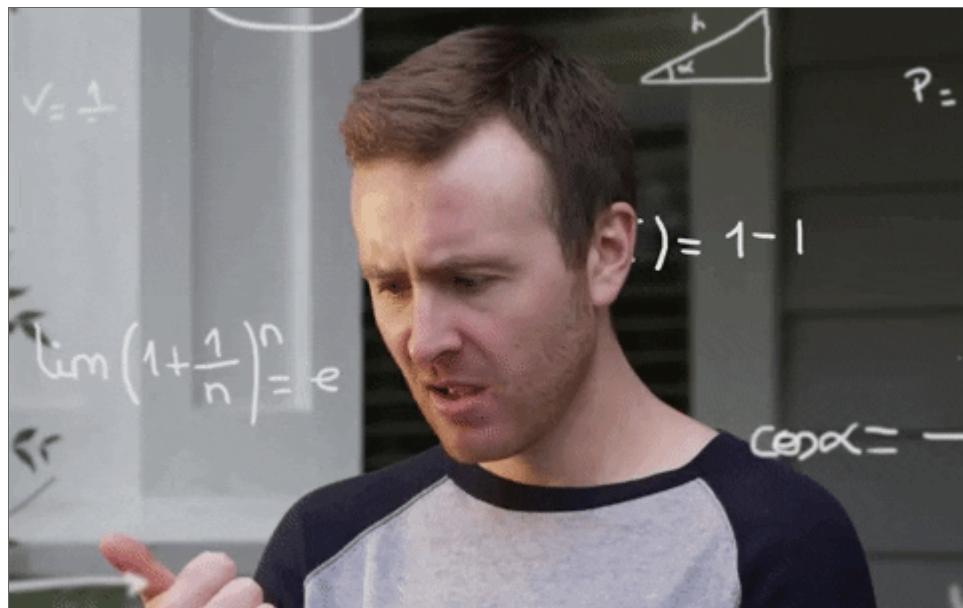
- graphicalVAR Formel

$$Tired_t = a * Tired_{t-1} + b * Activity_{t-1} + \epsilon_t$$

$$Y_t = \mathbf{B}Y_{t-1} + \Sigma$$

- Regularisierung für Struktur

# Auszeit



<https://media.giphy.com/media/IHfxDepSGIzom6f65K/giphy.gif>

## Zwischenfazit

- Netzwerke sind überall
- attraktive Alternative zur Konzeptualisierung von Psychopathologie
- Mittlerweile sehr viele Querschnittsstudien, wichtig Hype von tatsächlicher Aussage zu trennen
- Längsschnitt ermöglicht neue Einblicke
- verschiedene Schätzmethoden

# Temporal Network

- Effekt von Variablen auf sich selbst und auf andere über die Zeit
- meist: Lag 1 - aber: Theorie?
- Granger Kausalität

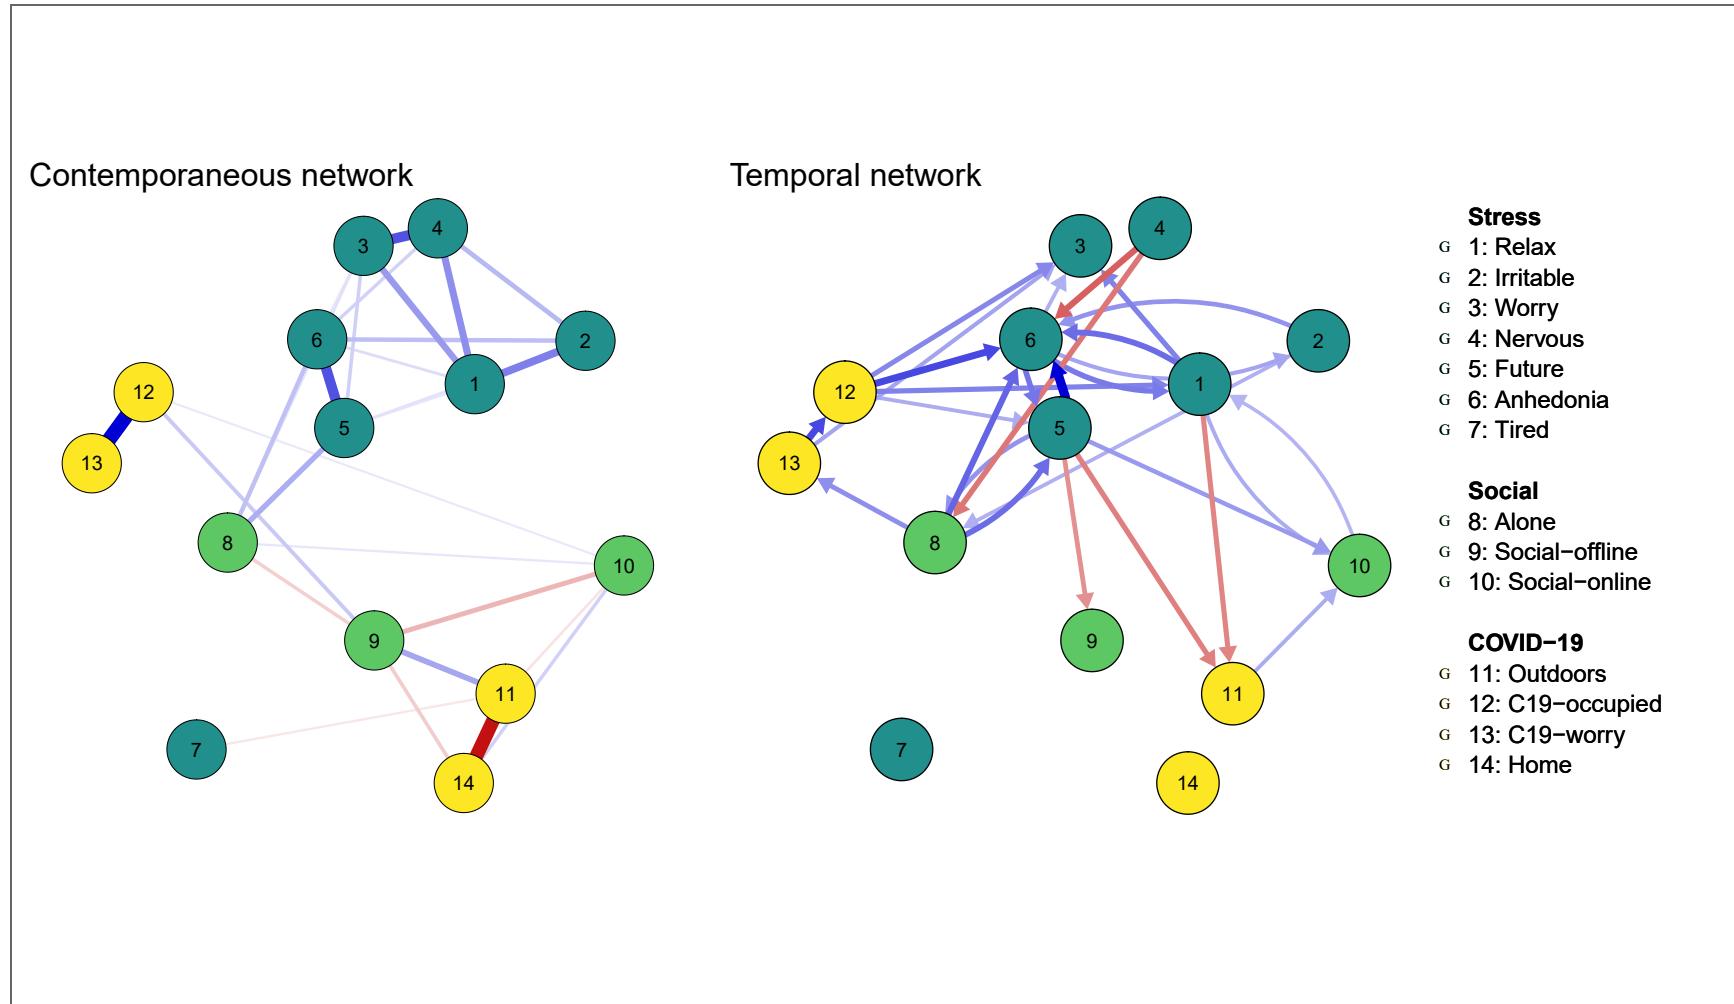
## Contemporaneous Network

- enthält Effekte, die temporales Netzwerk nicht einfängt
- etwa: Effekte, die schneller sind als Erhebungsfrequenz
- Beispiel:

*Stress → ErwartungPanik → Angst*

Beispiel aus Epskamp et al. (2018)

# Beispiel: Fried et al. (2020)

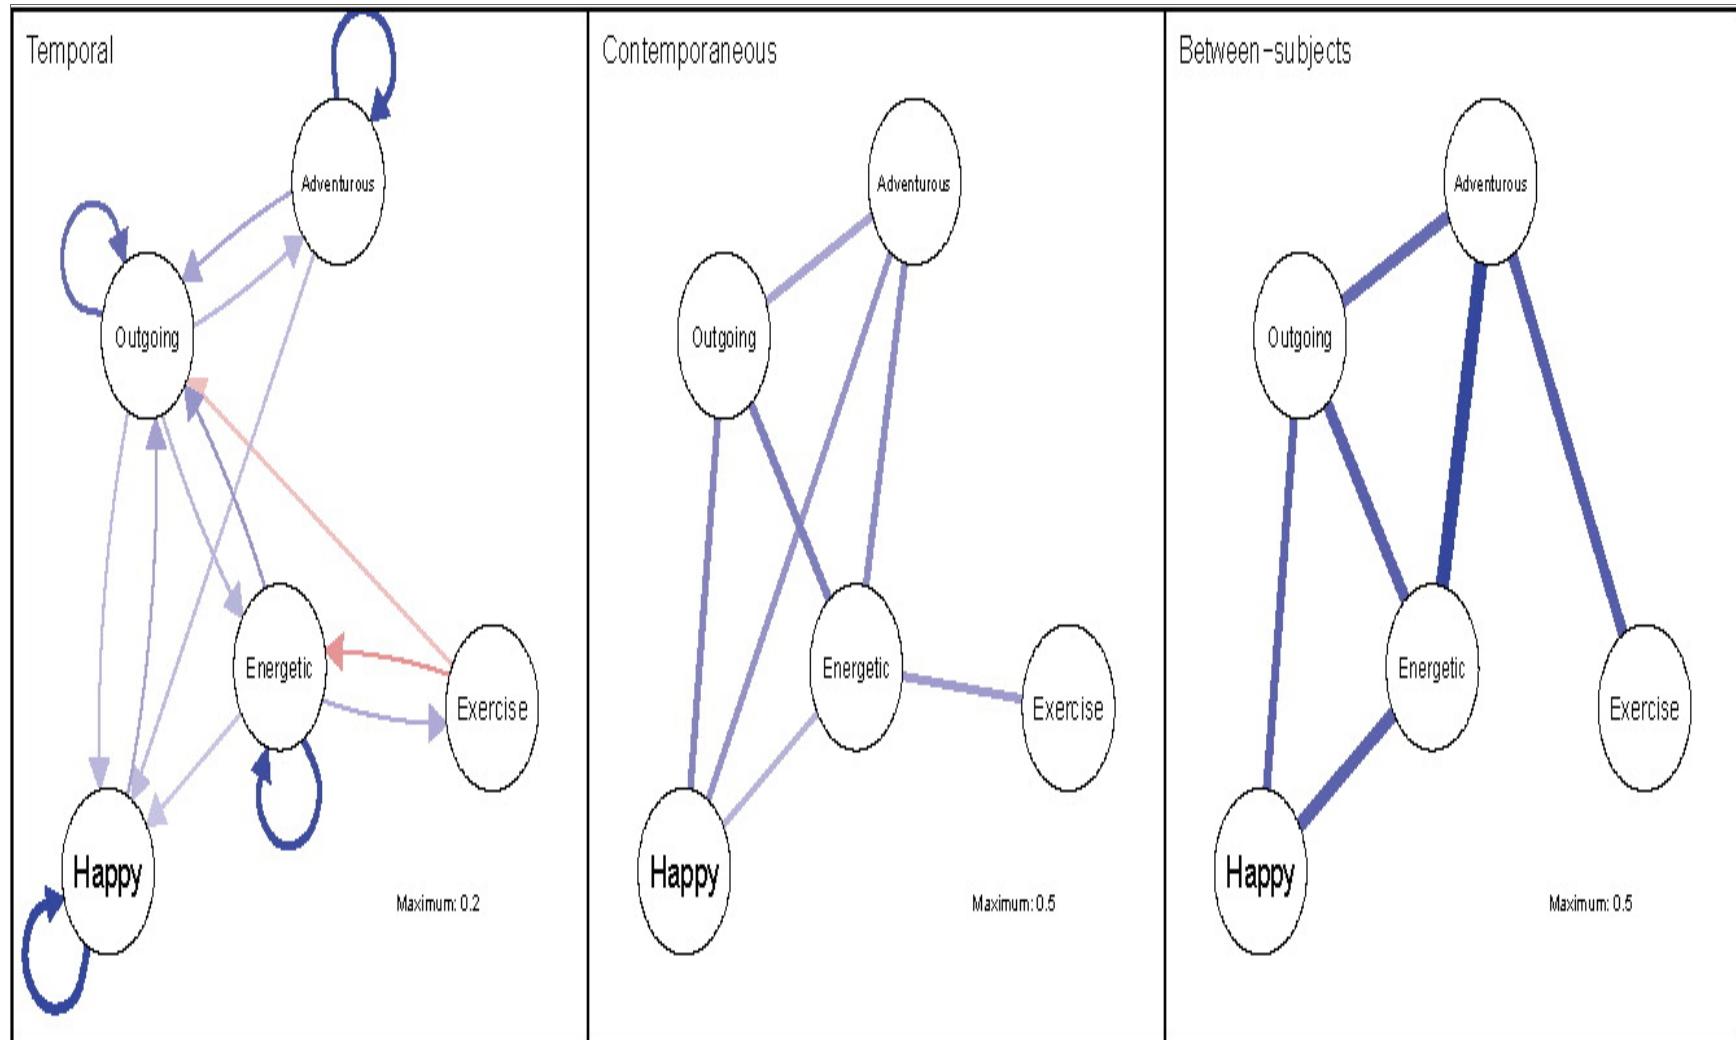


# Multilevelnetzwerke

- Vorteile:
  - mehr Power
  - Betrachtung von Heterogenität
  - weniger Zeitpunkte notwendig
- nicht ganz idiographisch
- mlVAR (Epskamp et al., 2018)
- GIMME (Beltz et al., 2016)
- DSEM (Asparouhov et al., 2018)

Simple Übersicht in Jordan et al. (2020)

# Ein Beispiel Multilevel



Epskamp et al. (2018)

# Interpretation

- gleiche Zeitabstände zwischen Messungen
  - Alternative: Continuous Time
- Korrekte Zeitabstände für zu messende Konstrukte
- Kausalität?
- Stationaritätsannahme
- Stabilität idiographischer Netzwerkschätzungen
- Missing Data
- Verteilungsannahmen

## Stabilität der Schätzung

- Hoekstra Paper
- Wir klonen das “wahre” Netzwerk einer Person und rechnen Netzwerkanalysen
- Ergebnis: Heterogenität
- Interpretation?
- Anzahl Zeitpunkte?

Hoekstra et al. (2022), Mansueto et al. (2022)

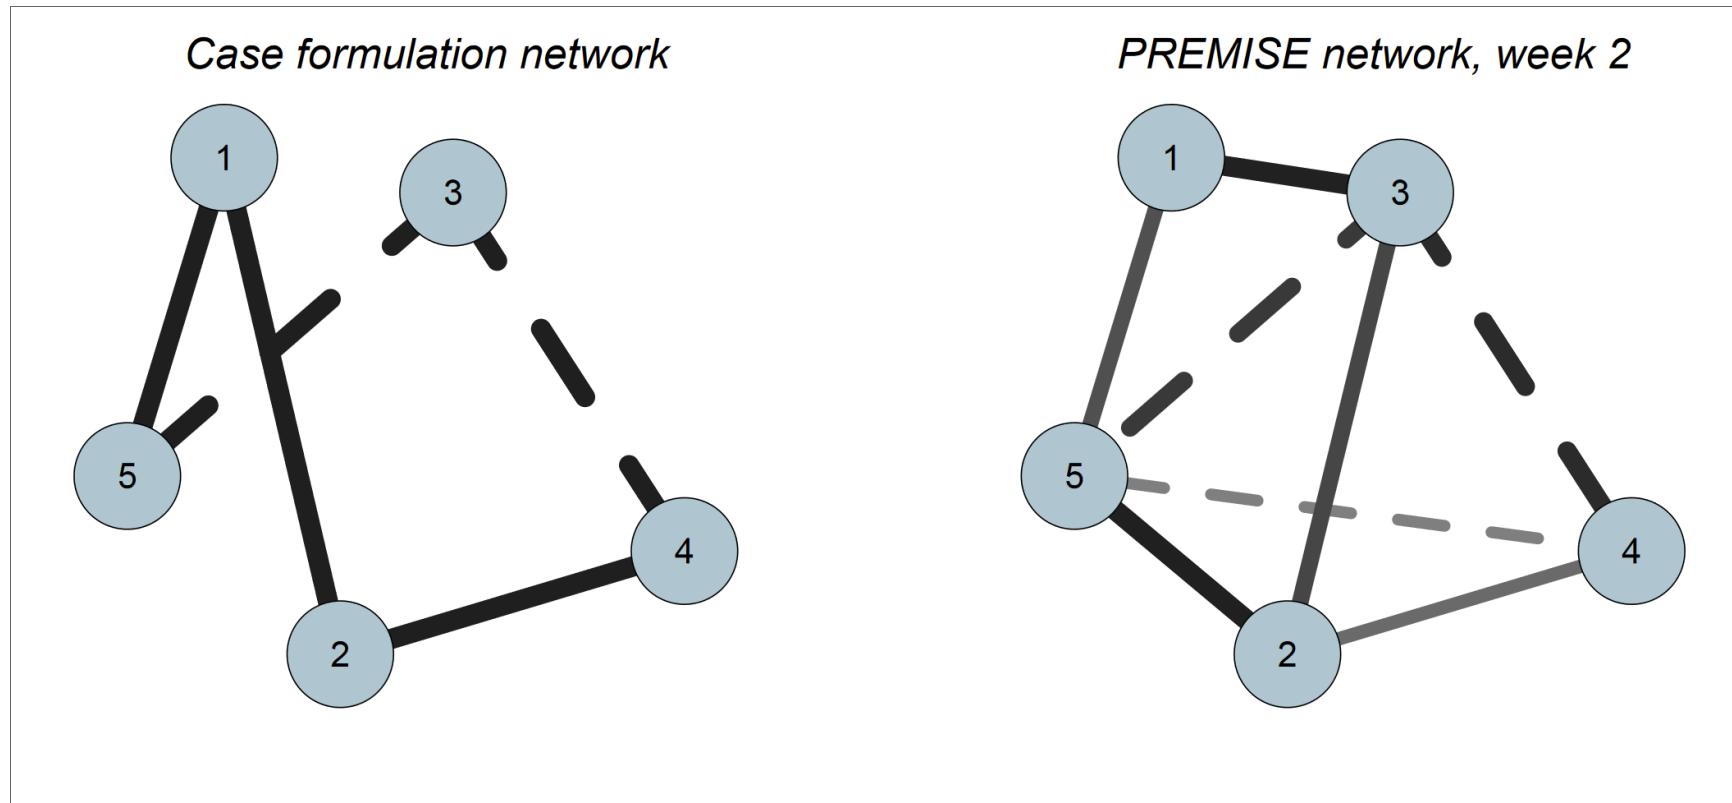
# Evidenz bei Einsatz in klinischer Praxis

- Frumkin et al. (2021):
  - wenige Fallstudien
  - Patient\*innen überzeugter als Therapeut\*innen
- Levinson et al. (2023):
  - n = 79, Essstörungen
  - Modulwahl anhand von Netzwerken
- Hall et al. (2022):
  - Einzelfallstudie zu TheraNET
  - Gutes Beispiel für detailliertes, netzwerkbasieretes Feedback
- Keine eindeutige Evidenz (RCTs)
- viele unterschiedliche Möglichkeiten des Einsatzes

## Neuere Entwicklungen

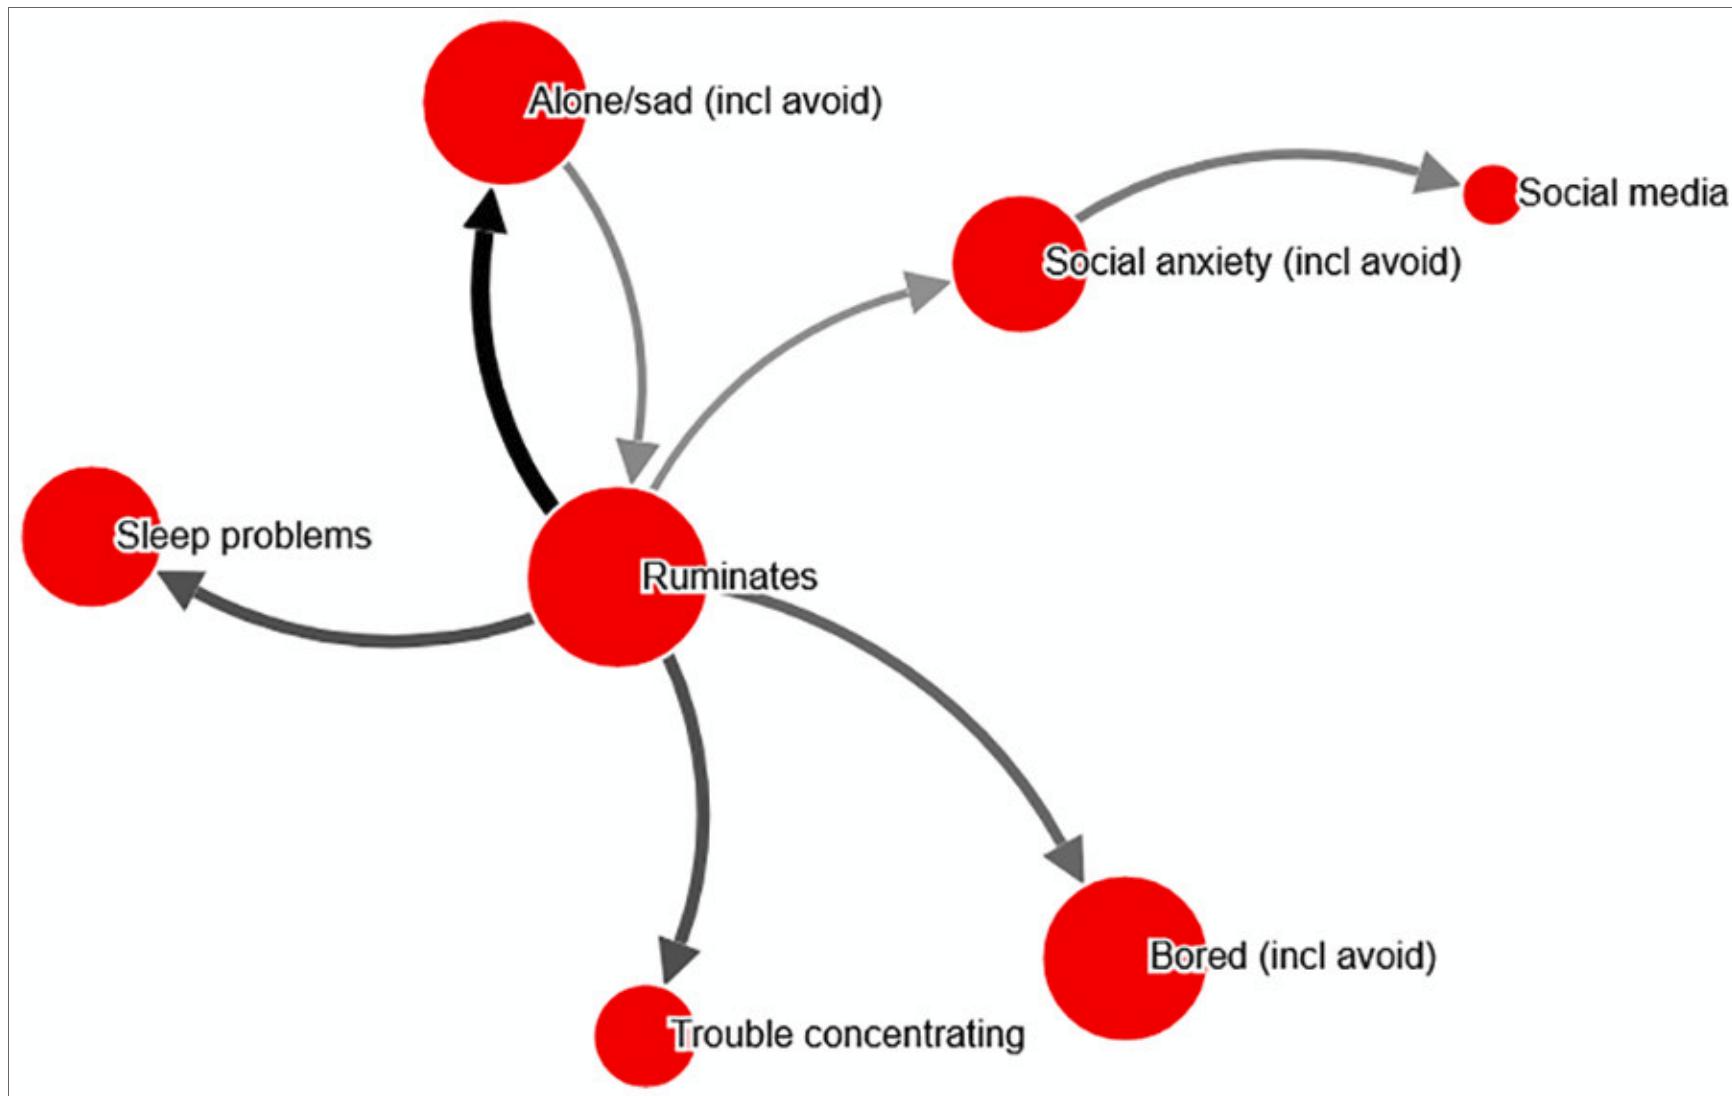
- Zusammenarbeit von Therapeut\*in/Patient\*in und Daten
- Veränderungen über die Zeit
- Vorhersage von Therapieergebnissen

# PREMISE



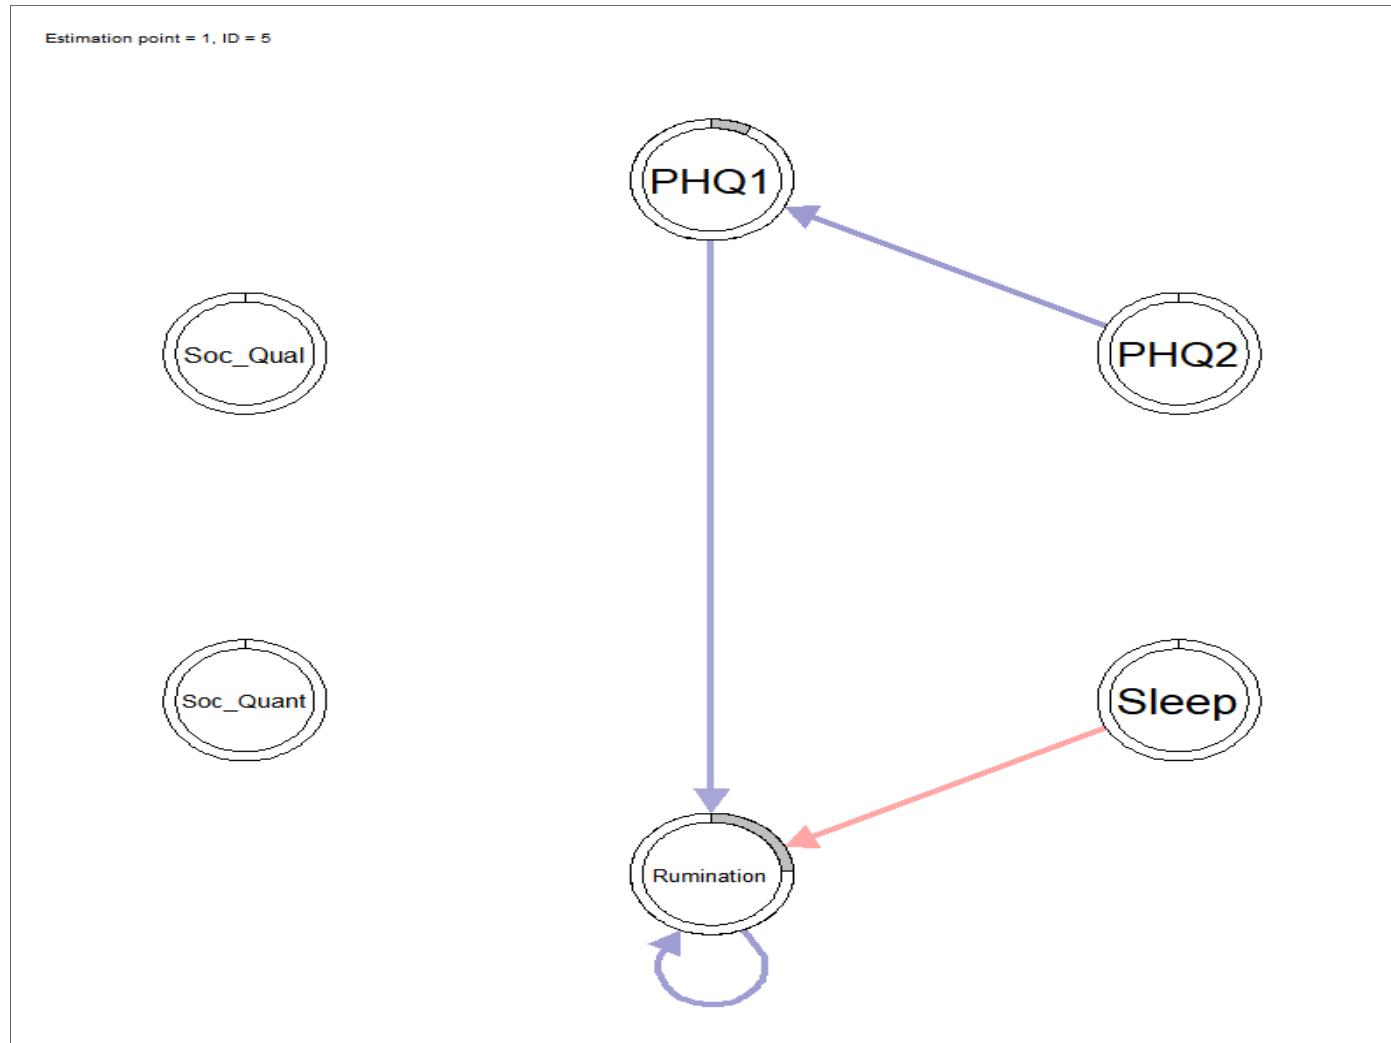
Burger et al. (2021), Burger et al. (2022)

# PECAN



Klintwall et al. (2021)

# Zeitlich variierende Netzwerke



Siepe et al. (2022)

# Vorhersage

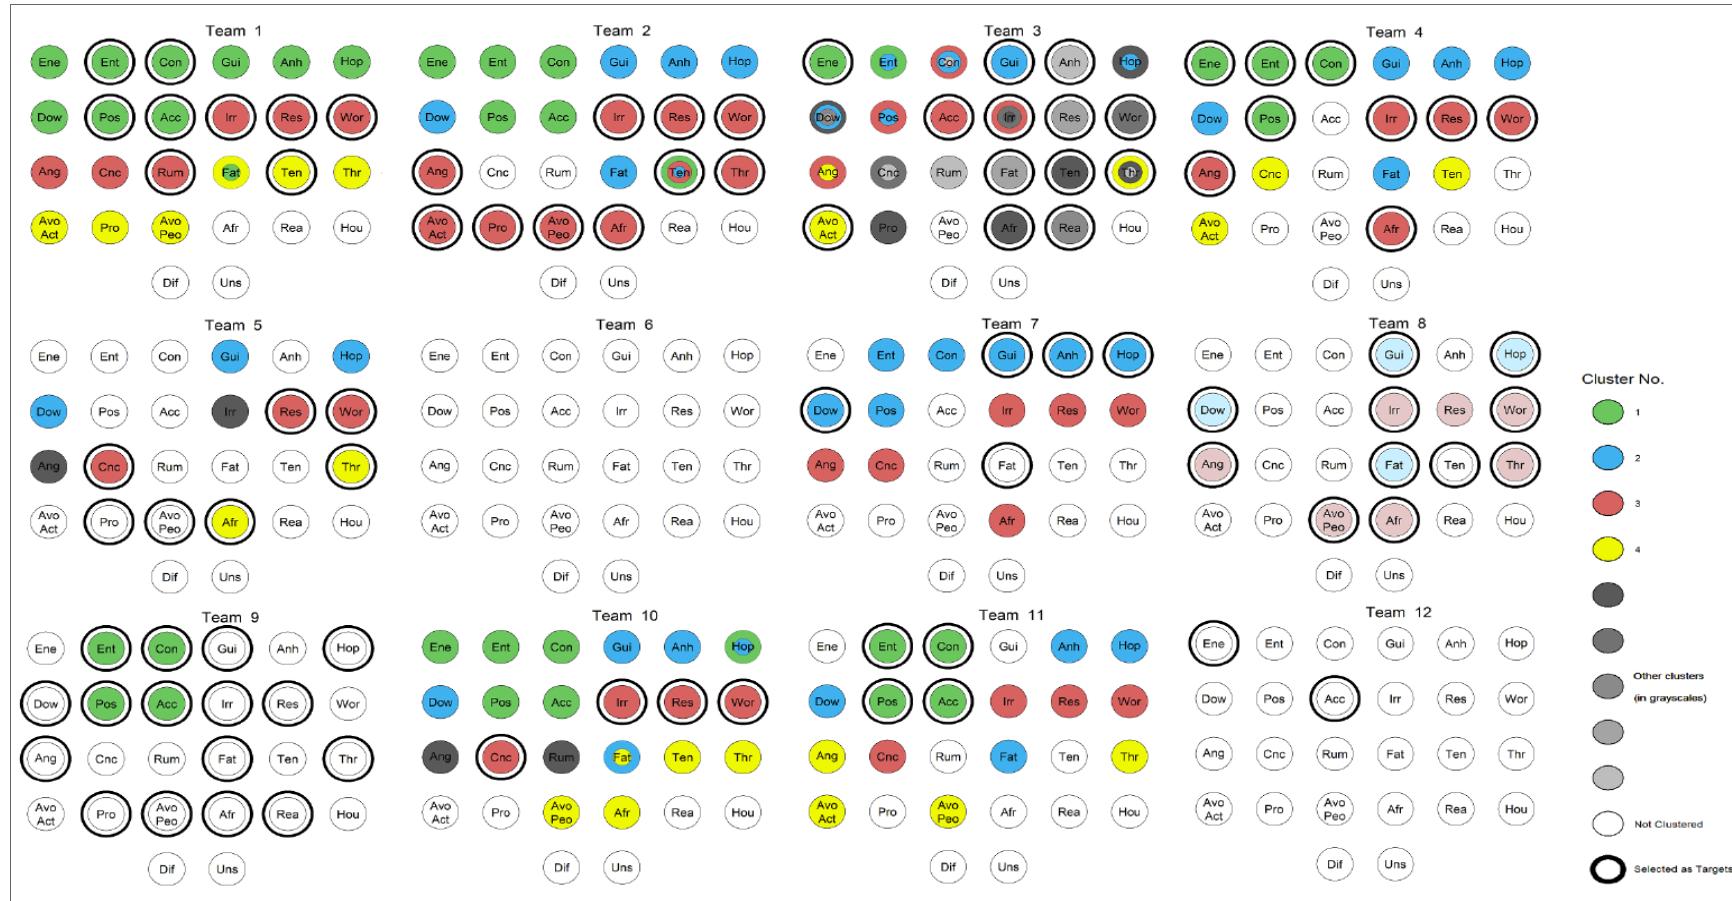
## Using network analysis for the prediction of treatment dropout in patients with mood and anxiety disorders: A methodological proof-of-concept study

Wolfgang Lutz<sup>ID</sup><sup>1</sup>, Brian Schwartz<sup>ID</sup><sup>1</sup>, Stefan G. Hofmann<sup>ID</sup><sup>2</sup>, Aaron J. Fisher<sup>3</sup>, Kristin Husen<sup>1</sup> & Julian A. Rubel<sup>ID</sup><sup>1</sup>

There are large health, societal, and economic costs associated with attrition from psychological services. The recently emerged, innovative statistical tool of complex network analysis was used in the present proof-of-concept study to improve the prediction of attrition. Fifty-eight patients undergoing psychological treatment for mood or anxiety disorders were assessed using Ecological Momentary Assessments four times a day for two weeks before treatment (3,248 measurements). Multilevel vector autoregressive models were employed to compute dynamic symptom networks. Intake variables and network parameters (centrality measures) were used as predictors for dropout using machine-learning algorithms. Networks for patients differed significantly between completers and dropouts. Among intake variables, initial impairment and sex predicted dropout explaining 6% of the variance. The network analysis identified four additional predictors: Expected force of being excited, outstrength of experiencing social support, betweenness of feeling nervous, and instrength of being active. The final model with the two intake and four network variables explained 32% of variance in dropout and identified 47 out of 58 patients correctly. The findings indicate that patients' dynamic network structures may improve the prediction of dropout. When implemented in routine care, such prediction models could identify patients at risk for attrition and inform personalized treatment recommendations.

Lutz et al. (2018)

# Welche Analysen?



Bastiaansen et al. (2019)

## Ausblick

- Was ist die Zukunft von Netzwerken im klinischen Setting?
- “More than a pretty picture?”
- Stabilität über die Zeit
- Verknüpfung von datengetriebenen Modellen und Theorien

# Zusammenfassung

1. Netzwerke sind konzeptuell attraktiv
2. Längsschnitt gibt uns neue Informationen ... aber auch neue Probleme
3. Hohe Diversität in Netzwerkansätzen
4. Fragen?

# Kontakt

 [Feel](#)

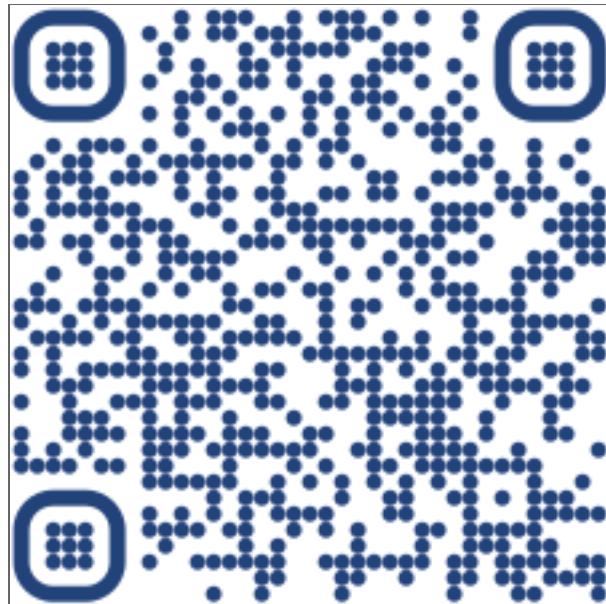
 [free](#)

 [to](#)

 [@contact](#)

 [me](#)

bjoern.siepe@uni-marburg.de



## Ressourcen

PNAWS 2020 - frei zugänglich. Diente teils als Inspiration für diesen Workshop, besonders die Folien von Julian Burger.

Psych Networks Blog - nicht mehr aktiv



# Literatur Querschnitt

Borsboom, D., & Cramer, A. O. J. (2013). Network analysis: An integrative approach to the structure of psychopathology. *Annual Review of Clinical Psychology*, 9(1), 91–121. <https://doi.org/10.1146/annurev-clinpsy-050212-185608>

Borsboom D. (2017). A network theory of mental disorders. *World psychiatry : official journal of the World Psychiatric Association (WPA)*, 16(1), 5–13. <https://doi.org/10.1002/wps.20375>

Borsboom, D., Deserno, M. K., Rhemtulla, M., Epskamp, S., Fried, E. I., McNally, R. J., Robinaugh, D. J., Perugini, M., Dalege, J., Costantini, G., Isvoranu, A.-M., Wysocki, A. C., van Borkulo, C. D., van Bork, R., & Waldorp, L. J. (2021). Network analysis of multivariate data in psychological science. *Nature Reviews Methods Primers*, 1(1), 1–18. <https://doi.org/10.1038/s43586-021-00055-w>

Dablander, F., Hinne, M. Node centrality measures are a poor substitute for causal inference. *Sci Rep* 9, 6846 (2019). <https://doi.org/10.1038/s41598-019-43033-9>

## Literatur Querschnitt

Fried, E.I., van Borkulo, C.D., Cramer, A.O.J. et al. Mental disorders as networks of problems: a review of recent insights. *Soc Psychiatry Psychiatr Epidemiol* 52, 1–10 (2017). <https://doi.org/10.1007/s00127-016-1319-z>

Fried, E. I., Epskamp, S., Nesse, R. M., Tuerlinckx, F., & Borsboom, D. (2016). What are ‘good’ depression symptoms? Comparing the centrality of DSM and non-DSM symptoms of depression in a network analysis. *Journal of affective disorders*, 189, 314–320. <https://doi.org/10.1016/j.jad.2015.09.005>

## Literatur

- Asparouhov, T., Hamaker, E. L., & Muthén, B. (2018). Dynamic structural equation models. *Structural Equation Modeling*, 25(3), 359–388.  
<https://doi.org/10.1080/10705511.2017.1406803>
- Beltz, A. M., Wright, A. G., Sprague, B. N., & Molenaar, P. C. (2016). Bridging the Nomothetic and Idiographic Approaches to the Analysis of Clinical Data. *Assessment*, 23(4), 447–458. <https://doi.org/10.1177/1073191116648209>
- Burger, J., Epskamp, S., Veen, D. C. van der, Dablander, F., Schoevers, R. A., Fried, E. I., & Riese, H. (2021). A clinical PREMISE for personalized models: Towards a formal integration of case formulations and statistical networks. *PsyArXiv*. <https://doi.org/10.31234/osf.io/bdrs7>
- Burger, J., Andikkhash, V., Jäger, N., Anderbro, T., Blanken, T., & Klintwall, L. (2022). A Novel Approach for Constructing Personalized Networks from Longitudinal Perceived Causal Relations. *PsyArXiv*. <https://doi.org/10.31234/osf.io/e93xd>

## Literatur

- Burger, J., Ralph-Nearman, C., & Levinson, C. A. (2022). Integrating clinician and patient case conceptualization with momentary assessment data to construct idiographic networks: Moving toward personalized treatment for eating disorders. *Behaviour Research and Therapy*, 159, 104221.  
<https://doi.org/10.1016/j.brat.2022.104221>
- Bringmann, L. F. (2021). Person-specific networks in psychopathology: Past, present and future. *Current Opinion in Psychology*, 41, 59–64. <https://doi.org/10.1016/j.copsyc.2021.03.004>
- Epskamp, S., Waldorp, L. J., Möttus, R., & Borsboom, D. (2018). The Gaussian graphical model in cross-sectional and time-series data. *Multivariate behavioral research*, 53(4), 453–480.
- Jordan, D. G., Winer, E. S., & Salem, T. (2020). The current status of temporal network analysis for clinical science: Considerations as the paradigm shifts? *Journal of Clinical Psychology*, 76(9), 1591–1612. <https://doi.org/10.1002/jclp.22957>

## Literatur

Klintwall, L., Bellander, M., & Cervin, M. (2023). Perceived Causal Problem Networks: Reliability, Central Problems, and Clinical Utility for Depression. *Assessment*, 30(1), 73–83. <https://doi.org/10.1177/10731911211039281>

von Klipstein, L., Riese, H., van der Veen, D. C., Servaas, M. N., & Schoevers, R. A. (2020). Using person-specific networks in psychotherapy: Challenges, limitations, and how we could use them anyway. *BMC Medicine*, 18(1), 345. <https://doi.org/10.1186/s12916-020-01818-0>

# Abbildungen

Jeremykemp at English Wikipedia ([https://commons.wikimedia.org/wiki/File:Gartner\\_Hype\\_Cycle.svg](https://commons.wikimedia.org/wiki/File:Gartner_Hype_Cycle.svg)), „Gartner Hype Cycle“, <https://creativecommons.org/licenses/by-sa/3.0/legalcode>

Foto von Sabina auf Unsplash

Foto von Jonas Leupe auf Unsplash

